

# 期望最大

期望最大算法的目的是解决具有隐变量的混合模型的参数估计（极大似然估计）。MLE 对  $p(x|\theta)$  参数的估计记为： $\theta_{MLE} = \underset{\theta}{argmax} \log p(x|\theta)$ 。EM 算法对这个问题的解决方法是采用迭代的方法：

$$\theta^{t+1} = \underset{\theta}{argmax} \int_z \log[p(x, z|\theta)]p(z|x, \theta^t)dz = \mathbb{E}_{z|x, \theta^t} [\log p(x, z|\theta)] \quad (1)$$

这个公式包含了迭代的两步：

1. E step: 计算  $\log p(x, z|\theta)$  在概率分布  $p(z|x, \theta^t)$  下的期望
2. M step: 计算使这个期望最大化的参数得到下一个 EM 步骤的输入

求证： $\log p(x|\theta^t) \leq \log p(x|\theta^{t+1})$

证明： $\log p(x|\theta) = \log p(z, x|\theta) - \log p(z|x, \theta)$ ，对左右两边求积分：

$$Left: \int_z p(z|x, \theta^t) \log p(x|\theta) dz = \log p(x|\theta) \quad (2)$$

$$Right: \int_z p(z|x, \theta^t) \log p(x, z|\theta) dz - \int_z p(z|x, \theta^t) \log p(z|x, \theta) dz = Q(\theta, \theta^t) - H(\theta, \theta^t) \quad (18)$$

所以：

$$\log p(x|\theta) = Q(\theta, \theta^t) - H(\theta, \theta^t) \quad (4)$$

由于  $Q(\theta, \theta^t) = \int_z p(z|x, \theta^t) \log p(x, z|\theta) dz$ ，而

$\theta^{t+1} = \underset{\theta}{argmax} \int_z \log[p(x, z|\theta)]p(z|x, \theta^t)dz$ ，所以  $Q(\theta^{t+1}, \theta^t) \geq Q(\theta^t, \theta^t)$ 。要证

$\log p(x|\theta^t) \leq \log p(x|\theta^{t+1})$ ，需证： $H(\theta^t, \theta^t) \geq H(\theta^{t+1}, \theta^t)$ ：

$$\begin{aligned} H(\theta^{t+1}, \theta^t) - H(\theta^t, \theta^t) &= \int_z p(z|x, \theta^t) \log p(z|x, \theta^{t+1}) dz - \int_z p(z|x, \theta^t) \log p(z|x, \theta^t) dz \\ &= \int_z p(z|x, \theta^t) \log \frac{p(z|x, \theta^{t+1})}{p(z|x, \theta^t)} = -KL(p(z|x, \theta^{t+1}), p(z|x, \theta^t)) \leq 0 \quad (5) \end{aligned}$$

综合上面的结果：

$$\log p(x|\theta^t) \leq \log p(x|\theta^{t+1}) \quad (6)$$

根据上面的证明，我们看到，似然函数在每一步都会增大。进一步的，我们看 EM 迭代过程中的式子是怎么来的：

$$\log p(x|\theta) = \log p(z, x|\theta) - \log p(z|x, \theta) = \log \frac{p(z, x|\theta)}{q(z)} - \log \frac{p(z|x, \theta)}{q(z)} \quad (7)$$

分别对两边求期望  $\mathbb{E}_{q(z)}$ ：

$$Left : \int_z q(z) \log p(x|\theta) dz = \log p(x|\theta) \quad (8)$$

$$Right : \int_z q(z) \log \frac{p(z, x|\theta)}{q(z)} dz - \int_z q(z) \log \frac{p(z|x, \theta)}{q(z)} dz = ELBO + KL(p(z|x, \theta), q(z)) \quad (9)$$

上式中, Evidence Lower Bound(ELBO), 是一个下界, 所以  $\log p(x|\theta) \geq ELBO$ , 等于号取在 KL 散度为0是, 即:  $q(z) = p(z|x, \theta)$ , EM 算法的目的是将 ELBO 最大化, 根据上面的证明过程, 在每一步 EM 后, 求得了最大的ELBO, 并根据这个使 ELBO 最大的参数代入下一步中:

$$\hat{\theta} = \underset{\theta}{argmax} ELBO = \underset{\theta}{argmax} \int_z q(z) \log \frac{p(x, z|\theta)}{q(z)} dz \quad (10)$$

由于  $q(z) = p(z|x, \theta^t)$  的时候, 这一步的最大值才能取等号, 所以:

$$\begin{aligned} \hat{\theta} &= \underset{\theta}{argmax} ELBO = \underset{\theta}{argmax} \int_z q(z) \log \frac{p(x, z|\theta)}{q(z)} dz = \underset{\theta}{argmax} \int_z p(z|x, \theta^t) \log \frac{p(x, z|\theta)}{p(z|x, \theta^t)} dz \\ &= \underset{\theta}{argmax} \int_z p(z|x, \theta^t) \log p(x, z|\theta) \end{aligned} \quad (11)$$

这个式子就是上面 EM 迭代过程中的式子。

从 Jensen 不等式出发, 也可以导出这个式子:

$$\begin{aligned} \log p(x|\theta) &= \log \int_z p(x, z|\theta) dz = \log \int_z \frac{p(x, z|\theta)q(z)}{q(z)} dz \\ &= \log \mathbb{E}_{q(z)} \left[ \frac{p(x, z|\theta)}{q(z)} \right] \geq \mathbb{E}_{q(z)} \left[ \log \frac{p(x, z|\theta)}{q(z)} \right] \end{aligned} \quad (12)$$

其中, 右边的式子就是 ELBO, 等号在  $p(x, z|\theta) = Cq(z)$  时成立。于是:

$$\begin{aligned} \int_z q(z) dz &= \frac{1}{C} \int_z p(x, z|\theta) dz = \frac{1}{C} p(x|\theta) = 1 \\ \Rightarrow q(z) &= \frac{1}{p(x|\theta)} p(x, z|\theta) = p(z|x, \theta) \end{aligned} \quad (13)$$

我们发现, 这个过程就是上面的最大值取等号的条件。

## 广义 EM

EM 模型解决了概率生成模型的参数估计的问题, 通过引入隐变量  $z$ , 来学习  $\theta$ , 具体的模型对  $z$  有不同的假设。对学习任务  $p(x|\theta)$ , 就是学习任务  $\frac{p(x, z|\theta)}{p(z|x, \theta)}$ 。在这个式子中, 我们假定了在 E 步骤中,  $q(z) = p(z|x, \theta)$ , 但是这个  $p(z|x, \theta)$  如果无法求解, 那么必须使用采样 (MCMC) 或者变分推断等方法来近似推断这个后验。我们观察 KL 散度的表达式, 为了最大化 ELBO, 在固定的  $\theta$  时, 我们需要最小化 KL 散度, 于是:

$$\hat{q}(z) = \underset{q}{argmin} KL(p, q) = \underset{q}{argmax} ELBO \quad (14)$$

这就是广义 EM 的基本思路:

1. E step:

$$\hat{q}^{t+1}(z) = \underset{q}{argmax} \int_z q^t(z) \log \frac{p(x, z|\theta)}{q^t(z)} dz, \text{fixed } \theta \quad (15)$$

2. M step:

$$\hat{\theta} = \underset{\theta}{argmax} \int_z \hat{q}^{t+1}(z) \log \frac{p(x, z|\theta)}{\hat{q}^{t+1}(z)} dz, \text{fixed } \hat{q} \quad (16)$$

对于上面的积分：

$$ELBO = \int_z q(z) \log \frac{p(x, z|\theta)}{q(z)} dz = \mathbb{E}_{q(z)}[p(x, z|\theta)] + Entropy(q(z)) \quad (17)$$

因此，我们看到，广义 EM 相当于在原来的式子中加入熵这一项。

## EM 的推广

---

EM 算法类似于坐标上升法，固定部分坐标，优化其他坐标，再一遍一遍的迭代。如果在 EM 框架中，无法求解  $z$  后验概率，那么需要采用一些变种的 EM 来估算这个后验。

1. 基于平均场的变分推断，VBEM/VEM
2. 基于蒙特卡洛的EM，MCEM