

线性动态系统

HMM 模型适用于隐变量是离散的值的时候，对于连续隐变量的 HMM，常用线性动态系统描述线性高斯模型的态变量，使用粒子滤波来表述非高斯非线性的态变量。

LDS 又叫卡尔曼滤波，其中，线性体现在上一时刻和这一时刻的隐变量以及隐变量和观测之间：

$$z_t = A \cdot z_{t-1} + B + \varepsilon \quad (1)$$

$$x_t = C \cdot z_t + D + \delta \quad (2)$$

$$\varepsilon \sim \mathcal{N}(0, Q) \quad (3)$$

$$\delta \sim \mathcal{N}(0, R) \quad (4)$$

类比 HMM 中的几个参数：

$$p(z_t | z_{t-1}) \sim \mathcal{N}(A \cdot z_{t-1} + B, Q) \quad (5)$$

$$p(x_t | z_t) \sim \mathcal{N}(C \cdot z_t + D, R) \quad (6)$$

$$z_1 \sim \mathcal{N}(\mu_1, \Sigma_1) \quad (7)$$

在含时的概率图中，除了对参数估计的学习问题外，在推断任务中，包括译码，证据概率，滤波，平滑，预测问题，LDS 更关心滤波这个问题： $p(z_t | x_1, x_2, \dots, x_t)$ 。类似 HMM 中的前向算法，我们需要找到一个递推关系。

$$p(z_t | x_{1:t}) = p(x_{1:t}, z_t) / p(x_{1:t}) = Cp(x_{1:t}, z_t) \quad (8)$$

对于 $p(x_{1:t}, z_t)$ ：

$$\begin{aligned} p(x_{1:t}, z_t) &= p(x_t | x_{1:t-1}, z_t) p(x_{1:t-1}, z_t) = p(x_t | z_t) p(x_{1:t-1}, z_t) \\ &= p(x_t | z_t) p(z_t | x_{1:t-1}) p(x_{1:t-1}) = Cp(x_t | z_t) p(z_t | x_{1:t-1}) \end{aligned} \quad (9)$$

我们看到，右边除了只和观测相关的常数项，还有一项是预测任务需要的概率。对这个值：

$$\begin{aligned} p(z_t | x_{1:t-1}) &= \int_{z_{t-1}} p(z_t, z_{t-1} | x_{1:t-1}) dz_{t-1} \\ &= \int_{z_{t-1}} p(z_t | z_{t-1}, x_{1:t-1}) p(z_{t-1} | x_{1:t-1}) dz_{t-1} \\ &= \int_{z_{t-1}} p(z_t | z_{t-1}) p(z_{t-1} | x_{1:t-1}) dz_{t-1} \end{aligned} \quad (10)$$

我们看到，这又化成了一个滤波问题。于是我们得到了一个递推公式：

1. $t = 1$, $p(z_1 | x_1)$ ，称为 update 过程，然后计算 $p(z_2 | x_1)$ ，通过上面的积分进行，称为 prediction 过程。
2. $t = 2$, $p(z_2 | x_2, x_1)$ 和 $p(z_3 | x_1, x_2)$

我们看到，这个过程是一个 Online 的过程，对于我们的线性高斯假设，这个计算过程都可以得到解析解。

1. Prediction:

$$p(z_t | x_{1:t-1}) = \int_{z_{t-1}} p(z_t | z_{t-1}) p(z_{t-1} | x_{1:t-1}) dz_{t-1} = \int_{z_{t-1}} \mathcal{N}(Az_{t-1} + B, Q) \mathcal{N}(\mu_{t-1}, \Sigma_{t-1}) dz_{t-1} \quad (11)$$

其中第二个高斯分布是上一步的 Update 过程，所以根据线性高斯模型，直接可以写出这个积分：

$$p(z_t | x_{1:t-1}) = \mathcal{N}(A\mu_{t-1} + B, Q + A\Sigma_{t-1}A^T) \quad (12)$$

2. Update:

$$p(z_t | x_{1:t}) \propto p(x_t | z_t) p(z_t | x_{1:t-1}) \quad (14)$$

同样利用线性高斯模型，也可以直接写出这个高斯分布。