高斯网络

高斯图模型(高斯网络)是一种随机变量为连续的有向或者无向图。有向图版本的高斯图是高斯贝叶斯 网络,无向版本的叫高斯马尔可夫网络。

高斯网络的每一个节点都是高斯分布: $\mathcal{N}(\mu_i,\Sigma_i)$,于是所有节点的联合分布就是一个高斯分布,均值为 μ ,方差为 Σ 。

对于边缘概率, 我们有下面三个结论:

- 1. 对于方差矩阵,可以得到独立性条件: $x_i \perp x_j \Leftrightarrow \sigma_{ij} = 0$,这个叫做全局独立性。
- 2. 我们看方差矩阵的逆(精度矩阵或信息矩阵): $\Lambda=\Sigma^{-1}=(\lambda_{ij})_{pp}$,有定理:

$$x_i \perp x_j | (X - \{x_i, x_j\}) \Leftrightarrow \lambda_{ij} = 0$$

因此,我们使用精度矩阵来表示条件独立性。

3. 对于任意一个无向图中的节点 $x_i, \,\, x_i | (X-x_i) \sim \mathcal{N}(\sum\limits_{j \neq i} rac{\lambda_{ij}}{\lambda_{ii}} x_j, \lambda_{ii}^{-1})$

也就是其他所有分量的线性组合,即所有与它有链接的分量的线性组合。

高斯贝叶斯网络 GBN

高斯贝叶斯网络可以看成是 LDS 的一个推广,LDS 的假设是相邻时刻的变量之间的依赖关系,因此是一个局域模型,而高斯贝叶斯网络,每一个节点的父亲节点不一定只有一个,因此可以看成是一个全局的模型。根据有向图的因子分解:

$$p(x) = \prod_{i=1}^{p} p(x_i | x_{Parents(i)})$$
 (1)

对里面每一项, 假设每一个特征是一维的, 可以写成线性组合:

$$p(x_i|x_{Parents(i)}) = \mathcal{N}(x_i|\mu_i + W_i^T x_{Parents(i)}, \sigma_i^2)$$
 (2)

将随机变量写成:

$$x_i = \mu_i + \sum_{j \in x_{Parents(i)}} w_{ij}(x_j - \mu_j) + \sigma_i \varepsilon_i, \varepsilon_i \sim \mathcal{N}(0, 1)$$
 (3)

写成矩阵形式,并且对w进行扩展:

$$x - \mu = W(x - \mu) + S\varepsilon \tag{4}$$

其中, $S = diag(\sigma_i)$ 。所以有: $x - \mu = (\mathbb{I} - W)^{-1}S\varepsilon$

由于:

$$Cov(x) = Cov(x - \mu) \tag{5}$$

可以得到协方差矩阵。

高斯马尔可夫网络 GMN

对于无向图版本的高斯网络, 可以写成:

$$p(x) = \frac{1}{Z} \prod_{i=1}^{p} \phi_i(x_i) \prod_{i,j \in X} \phi_{i,j}(x_i, x_j)$$
 (6)

为了将高斯分布和这个式子结合,我们写出高斯分布和变量相关的部分:

$$p(x) \propto \exp(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu))$$

$$= \exp(-\frac{1}{2}(x^T \Lambda x - 2\mu^T \Lambda x + \mu^T \Lambda \mu))$$

$$= \exp(-\frac{1}{2}x^T \Lambda x + (\Lambda \mu)^T x)$$
(7)

可以看到,这个式子与无向图分解中的两个部分对应,我们记 $h=\Lambda\mu$ 为 Potential Vector。其中和 x_i 相关的为: $x_i:-\frac{1}{2}\lambda_{ii}x_i^2+h_ix_i$,与 x_i,x_j 相关的是: $x_i,x_j:-\lambda_{ij}x_ix_j$,这里利用了精度矩阵为对称矩阵的性质。我们看到,这里也可以看出, x_i,x_j 构成的一个势函数,只和 λ_{ij} 有关,于是 $x_i\perp x_j|(X-\{x_i,x_j\})\Leftrightarrow \lambda_{ij}=0$ 。