

受限玻尔兹曼机

玻尔兹曼机是一种存在隐节点的无向图模型。在图模型中最简单的是朴素贝叶斯模型（朴素贝叶斯假设），引入单个隐变量后，发展出了 GMM，如果单个隐变量变成序列的隐变量，就得到了状态空间模型（引入齐次马尔可夫假设和观测独立假设就有 HMM，Kalman Filter，Particle Filter），为了引入观测变量之间的关联，引入了一种最大熵模型-MEMM，为了克服 MEMM 中的局域问题，又引入了 CRF，CRF 是一个无向图，其中，破坏了齐次马尔可夫假设，如果隐变量是一个链式结构，那么又叫线性链 CRF。

在无向图的基础上，引入隐变量得到了玻尔兹曼机，这个图模型的概率密度函数是一个指数族分布。对隐变量和观测变量作出一定的限制，就得到了受限玻尔兹曼机（RBM）。

我们看到，不同的概率图模型对下面几个特点作出假设：

1. 方向-边的性质
2. 离散/连续/混合-点的性质
3. 条件独立性-边的性质
4. 隐变量-节点的性质
5. 指数族-结构特点

将观测变量和隐变量分别记为 $v, h, h = \{h_1, \dots, h_m\}, v = \{v_1, \dots, v_n\}$ 。我们知道，无向图根据最大团的分解，可以写为玻尔兹曼分布的形式 $p(x) = \frac{1}{Z} \prod_{i=1}^K \psi_i(x_{ci}) = \frac{1}{Z} \exp(-\sum_{i=1}^K E(x_{ci}))$ ，这也是一个指数族分布。

一个玻尔兹曼机存在一系列的问题，在其推断任务中，想要精确推断，是无法进行的，想要近似推断，计算量过大。为了解决这个问题，一种简化的玻尔兹曼机-受限玻尔兹曼机作出了假设，所有隐变量内部以及观测变量内部没有连接，只在隐变量和观测变量之间有连接，这样一来：

$$p(x) = p(h, v) = \frac{1}{Z} \exp(-E(v, h)) \quad (1)$$

其中能量函数 $E(v, h)$ 可以写出三个部分，包括与节点集合相关的两项以及与边 w 相关的一项，记为：

$$E(v, h) = -(h^T w v + \alpha^T v + \beta^T h) \quad (2)$$

所以：

$$p(x) = \frac{1}{Z} \exp(h^T w v) \exp(\alpha^T v) \exp(\beta^T h) = \frac{1}{Z} \prod_{i=1}^m \prod_{j=1}^n \exp(h_i w_{ij} v_j) \prod_{j=1}^n \exp(\alpha_j v_j) \prod_{i=1}^m \exp(\beta_i h_i) \quad (3)$$

上面这个式子也和 RBM 的因子图一一对应。

推断

推断任务包括求后验概率 $p(v|h), p(h|v)$ 以及求边缘概率 $p(v)$ 。

$$p(h|v)$$

对于一个无向图，满足局域的 Markov 性质，即

$p(h_1|h - \{h_1\}, v) = p(h_1|Neighbour(h_1)) = p(h_1|v)$ 。我们可以得到：

$$p(h|v) = \prod_{i=1}^m p(h_i|v) \quad (4)$$

考虑 Binary RBM，所有的隐变量只有两个取值 0, 1：

$$p(h_l = 1|v) = \frac{p(h_l = 1, h_{-l}, v)}{p(h_{-l}, v)} = \frac{p(h_l = 1, h_{-l}, v)}{p(h_l = 1, h_{-l}, v) + p(h_l = 0, h_{-l}, v)} \quad (5)$$

将能量函数写成和 l 相关或不相关的两项：

$$E(v, h) = -(\sum_{i=1, i \neq l}^m \sum_{j=1}^n h_i w_{ij} v_j + h_l \sum_{j=1}^n w_{lj} v_j + \sum_{j=1}^n \alpha_j v_j + \sum_{i=1, i \neq l}^m \beta_i h_i + \beta_l h_l) \quad (6)$$

定义： $h_l H_l(v) = h_l \sum_{j=1}^n w_{lj} v_j + \beta_l h_l$, $\bar{H}(h_{-l}, v) = \sum_{i=1, i \neq l}^m \sum_{j=1}^n h_i w_{ij} v_j + \sum_{j=1}^n \alpha_j v_j + \sum_{i=1, i \neq l}^m \beta_i h_i$ 。

代入，有：

$$p(h_l = 1|v) = \frac{\exp(H_l(v) + \bar{H}(h_{-l}, v))}{\exp(H_l(v) + \bar{H}(h_{-l}, v)) + \exp(\bar{H}(h_{-l}, v))} = \frac{1}{1 + \exp(-H_l(v))} = \sigma(H_l(v)) \quad (7)$$

于是就得到了后验概率。对于 v 的后验是对称的，所以类似的可以求解。

$p(v)$

$$\begin{aligned} p(v) &= \sum_h p(h, v) = \sum_h \frac{1}{Z} \exp(h^T w v + \alpha^T v + \beta^T h) \\ &= \exp(\alpha^T v) \frac{1}{Z} \sum_{h_1} \exp(h_1 w_1 v + \beta_1 h_1) \cdots \sum_{h_m} \exp(h_m w_m v + \beta_m h_m) \\ &= \exp(\alpha^T v) \frac{1}{Z} (1 + \exp(w_1 v + \beta_1)) \cdots (1 + \exp(w_m v + \beta_m)) \\ &= \frac{1}{Z} \exp(\alpha^T v + \sum_{i=1}^m \log(1 + \exp(w_i v + \beta_i))) \end{aligned} \quad (8)$$

其中， $\log(1 + \exp(x))$ 叫做 Softplus 函数。